

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO

Relatório de Projeto - Projeto 1: Busca e Organização de Dados

Disciplina: Algoritmos e Estruturas de Dados I (SCC0202)

Carolina Goulart Kowalczuk, N°USP: 13854629
Júlia Barbosa Nogueira, N°USP: 17901347
Victor Hugo Adão de Oliveira, N°USP: 17969072

1. Resumo

Foi implementado um programa em C capaz de carregar, buscar e organizar registros usando diferentes estruturas de dados. O usuário pode escolher a estrutura que armazenará todo o dataset e a estrutura que armazenará os resultados da busca. Na primeira implementação, utilizamos um dataset de registros de aproximação de asteroides fornecido pelo professor da disciplina nas especificações do projeto. Na segunda implementação, escolhemos o dataset de Chamados de Tecnologia da Informação do MDHC, MIR e MMulheres de janeiro de 2026, que contém dados sobre os chamados atendidos pela central de serviços de TI e foi encontrado através do site de Dados Abertos do governo. Optamos pela escolha do segundo dataset por se aproximar da nossa área de atuação, considerando que todos os autores do programa cursam Ciência da Computação no ICMC-USP. As estruturas de dados implementadas disponíveis para utilização são: Pilha, Fila, Lista Sequencial, Lista Encadeada, Lista com Cabeça, Lista Ordenada, Lista Generalizada e Lista Cruzada.

2. Organização

Utilizamos um KANBAN para gestão do trabalho e divisão das tarefas para cada integrante do grupo. Além disso, adotamos uma subdivisão do projeto em subpastas, em que a pasta principal se chamava Busca-e-organizacao-de-dados e a partir dela criamos um repositório na plataforma GitHub para compartilharmos o código entre nós. A subpasta nomeada “include” contém todos os arquivos .h (headers), enquanto a “src” contém os códigos fonte no formato .c. Na pasta principal, exportamos os dois datasets asteroid_dataset e chamados_dataset em CSV para fazer os testes de execução. Separamos a pasta “consultas” para guardar os arquivos .txt com as especificações de cada consulta e os arquivos .csv gerados a partir delas. Após a construção do relatório experimental, foram adicionados na pasta principal o script .sh para rodar os testes.

O código foi dividido em módulos com responsabilidades separadas, de modo que as estruturas de dados não dependem de nenhum dataset específico:

- main: interpreta os argumentos da linha de comando, cria as estruturas escolhidas em --base e --result, chama o leitor, percorre a base aplicando a consulta, exporta os top-k primeiros registros do resultado para o arquivo de saída e imprime as métricas de tempo (carga, busca, inserção no resultado e escrita).
- reader e chamados_reader: são os únicos módulos específicos de cada dataset. Cada um lê o CSV, detecta o delimitador, converte cada linha válida em um ITEM e o insere na estrutura base. O leitor de asteroides mapeia as colunas pelo nome do cabeçalho. O de chamados trata campos vazios, campos entre aspas com quebra de linha e a conversão de codificação (Windows-1252 para UTF-8).

- item: define o ITEM, que guarda os dados de um asteroide ou de um chamado e a linha original do CSV. Permite acessar qualquer campo pelo nome, comparar dois itens por um campo e obter a chave de identificação. A linha original é mantida para que o arquivo de saída tenha exatamente o mesmo formato da entrada.
- query: lê o arquivo de consulta (FILTER, SIM, ACCEPT, ORDER, GROUP e CROSS) e avalia cada item: aplica todos os filtros, calcula a similaridade total como média ponderada dos critérios SIM e descarta o item se ela ficar abaixo do ACCEPT.
- estrutura: oferece uma interface única (criar, inserir, percorrer, tamanho e apagar) sobre as oito estruturas de dados. Assim, o main e os leitores funcionam com qualquer combinação de --base e --result. Para lista_gen e lista_cruz, as chaves de GROUP e CROSS são extraídas de cada item.
- TADs (pilha, fila, lista_seq, lista_enc, lista_cab, lista_gen e lista_cruz): cada estrutura trabalha apenas com ponteiros para ITEM e é independente do dataset. A lista ordenada (lista_ord) é a lista sequencial com inserção ordenada, que encontra a posição por busca binária e mantém a ordem durante a inserção.

3. Funcionamento

O programa opera através de uma interface de linha de comando (CLI) que processa datasets em formato CSV utilizando Tipos Abstratos de Dados (TADs) implementados em linguagem C. O fluxo de funcionamento divide-se em quatro etapas principais:

a) Leitura dos dados com "--reader" e "--input"

O programa identifica o tipo de leitor especificado via parâmetro ("nasa" ou "chamados"). Após isso, ele lê o arquivo CSV de entrada e converte internamente cada linha válida do dataset num ITEM.

b) Armazenamento na base "--base"

Todos os registros lidos são inseridos na estrutura de dados primária escolhida pelo usuário (ex: "fila", "lista_seq", etc.). Essa estrutura serve como o repositório principal de dados em memória para as operações seguintes.

c) Filtro e avaliação de consultas "--query"

Dentro da pasta consultas, cria-se um arquivo .txt com as regras da consulta especificadas pelo utilizador. Os critérios que podem ser utilizados são:

FILTER: condição obrigatória para o registro ser aceito;

SIM: critério numérico de similaridade, no formato campo|alvo|tolerância|peso;

ACCEPT: limiar mínimo para a similaridade total;

ORDER: chave usada pela lista ordenada;

GROUP: campos usados pela lista generalizada;

CROSS: campos usados pela lista cruzada.

Os registos que satisfazem os critérios são selecionados pelo programa.

d) Resultados e exportação "--result" e "--output"

Os registros filtrados são inseridos em uma estrutura de resultado secundária, escolhida com "--result". A ordenação (ORDER), o agrupamento (GROUP) e o cruzamento (CROSS) são definidos no arquivo da consulta e só têm efeito conforme a estrutura de resultado escolhida: ORDER em "lista_ord", GROUP em "lista_gen" e CROSS em "lista_cruz". Já FILTER, SIM e ACCEPT são aplicados na busca, qualquer que seja a estrutura. Por fim, o programa percorre esta estrutura de resultados e exporta os dados formatados para o arquivo de saída especificado ("--output"). É possível limitar a consulta no dataset com o “--limit”, que limita o número de registros válidos que serão lidos pelo programa para gerar o resultado. Também é possível limitar a quantidade de resultados gerados com “--top-k”, que exporta apenas o número especificado de itens (linhas) para o CSV dos resultados.

4. Exemplos de execução

4.1 Dataset Asteroides

i) Exemplo 1

a) Comando no terminal:

```
make && ./trabalho --reader nasa --input asteroid_dataset.csv --base lista_seq --result lista_ord --query consultas/q1.txt --output resultado_asteroides1.csv --top-k 5 --limit 1000
```

b) Definição da consulta no arquivo q1_asteroides.txt:

```
FILTER|distance_au|<=|0.05

FILTER|risk_score|>=|0.2

SIM|velocity_km_s|5.0|3.0|1.5

SIM|absolute_magnitude|22.0|5.0|1.0

ACCEPT|0.40
```

ORDER|similarity|DESC

GROUP|threat_category|year

CROSS|threat_category|year

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=68

OUTPUT_RECORDS=5

LOAD_MS=3.857

SEARCH_MS=0.198

RESULT_INSERT_MS=0.037

WRITE_MS=0.168

d) Tabela construída a partir do arquivo gerado resultado_asteroide1.csv:

asteroid_designation	distance_au	risk_score	velocity_km_s	absolute_magnitude
613400	0.0289	0.3662	5.0608	23.03
2019 YV	0.0443	0.3328	4.5370	23.60
2020 DB4	0.0350	0.3543	5.1415	25.40
2020 BR5	0.0417	0.3409	5.1299	25.50
2020 BE8	0.0287	0.3641	4.5519	25.18

ii) Exemplo 2

a) Comando no terminal:

make && ./trabalho --reader nasa --input asteroid_dataset.csv --base fila --result lista_ord --query consultas/q2_asteroides.txt --output consultas/resultado_asteroide2.csv --top-k 5 --limit 1000

b) Definição da consulta no arquivo q2_asteroides.txt:

FILTER|is_past_event|==|true

FILTER|threat_category|!=|SAFE

FILTER|distance_au|<|0.1

FILTER|absolute_magnitude|>|20

FILTER|close_approach_date|>=|2020-02-01

ORDER|close_approach_date|ASC

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=380

OUTPUT_RECORDS=5

LOAD_MS=4.712

SEARCH_MS=0.674

RESULT_INSERT_MS=0.527

WRITE_MS=0.140

d) Tabela construída a partir do arquivo gerado resultado_asteroide2.csv:

asteroid_designation	close_approach_date	threat_category	is_past_event	distance_au	absolute_magnitude
2020 CD1	2020-02-01 03:02:00	MONITOR	True	0.0194	26.10
755140	2020-02-01 08:18:00	MONITOR	True	0.0349	22.18
2020 CW	2020-02-01 12:50:00	CONCERN	True	0.0001	32.56
2020 BN12	2020-02-01 16:44:00	MONITOR	True	0.0088	25.90
2020 BU2	2020-02-01 21:46:00	MONITOR	True	0.0737	24.20

iii) Exemplo 3

a) Comando no terminal:

make && ./trabalho --reader nasa --input asteroid_dataset.csv --base lista_cabeca --result lista_gen --query consultas/q3_asteroides.txt --output consultas/resultado_asteroide3.csv --top-k 5 --limit 300

b) Definição da consulta no arquivo q3_asteroides.txt:

FILTER|is_future_event|==|false

FILTER|panic_level|>=|1

GROUP|threat_category|month|panic_level

CROSS|threat_category|panic_level

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=300

MATCHED_RECORDS=299

OUTPUT_RECORDS=5

LOAD_MS=1.328

SEARCH_MS=0.117

RESULT_INSERT_MS=0.493

WRITE_MS=0.195

d) Tabela construída a partir do arquivo gerado resultado_asteroide3.csv:

asteroid_designation	close_approach_date	threat_category	month	panic_level	is_future_event
2020 AY1	2020-01-01 00:54:00	MONITOR	1	4	False
2019 YK	2020-01-01 02:06:00	MONITOR	1	4	False
2020 AP3	2020-01-01 11:13:00	MONITOR	1	4	False
2020 AN2	2020-01-01 21:18:00	MONITOR	1	4	False
2020 AC	2020-01-02 06:56:00	MONITOR	1	4	False

4.2 Dataset Chamados de TI

i) Exemplo 1

a) Comando no terminal:

make && ./trabalho --reader chamados --input chamados_dataset.csv --base lista_seq --result lista_ord --query consultas/q1_chamados.txt --output consultas/resultado_chamados1.csv --top-k 5 --limit 1000

b) Definição da consulta no arquivo q1_chamados.txt:

FILTER|situacao|==|Fechada

FILTER|unidade|==|Ministério das Mulheres

ORDER|solicitacao|DESC

GROUP|grupo|situacao

CROSS|unidade|situacao

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=274

OUTPUT_RECORDS=5

LOAD_MS=5.149

SEARCH_MS=0.450

RESULT_INSERT_MS=0.130

WRITE_MS=0.127

d) Tabela construída a partir do arquivo gerado resultado_chamados1.csv:

Solicitação	Atividade	Data/Hora Abertura	Situação	Unidade
268911	Instalar ou desinstalar computador	29/01/2026 16:26	Fechada	Ministério das Mulheres
268904	Vincular ou	29/01/2026	Fechada	Ministério das

	desvincular e-mail de caixa compartilhada	16:23		Mulheres
268900	Vincular ou desvincular e-mail de caixa compartilhada	29/01/2026 16:18	Fechada	Ministério das Mulheres
268890	Mapear impressora no computador	29/01/2026 16:10	Fechada	Ministério das Mulheres
268887	Vincular ou desvincular e-mail de caixa compartilhada	29/01/2026 16:06	Fechada	Ministério das Mulheres

ii) Exemplo 2

a) Comando no terminal: make && ./trabalho --reader chamados --input chamados_dataset.csv --base fila --result lista_ord --query consultas/q2_chamados.txt --output consultas/resultado_chamados2.csv --top-k 5 --limit 1000
b) Definição da consulta no arquivo q2_chamados.txt:

FILTER|unidade|!=|Ministério das Mulheres

FILTER|solicitacao|>=|250000

FILTER|solicitacao|<|268000

FILTER|ano_abertura|==|2026

SIM|solicitacao|260000|10000|2.0

SIM|dia_abertura|15|10|1.0

ACCEPT|0.50

ORDER|similarity|DESC

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=449

OUTPUT_RECORDS=5

LOAD_MS=4.327

SEARCH_MS=0.545

RESULT_INSERT_MS=0.216

WRITE_MS=0.087

d) Tabela construída a partir do arquivo gerado resultado_chamados2.csv:

Solicitação	Atividade	Data/Hora Abertura	Unidade
259997	Instalar ou desinstalar computador	12/01/2026 08:29	Ministério dos Direitos Humanos e da Cidadania
260043	Verificar erro em computador	12/01/2026 09:18	Ministério dos Direitos Humanos e da Cidadania
260049	Configurar computador	12/01/2026 09:27	Ministério dos Direitos Humanos e da Cidadania
260056	Configurar computador	12/01/2026 09:29	Ministério dos Direitos Humanos e da Cidadania
260086	Configurar computador	12/01/2026 09:40	Ministério dos Direitos Humanos e da Cidadania

iii) Exemplo 3

a) Comando no terminal: make && ./trabalho --reader chamados --input chamados_dataset.csv --base lista_cabeca --result lista_ord --query consultas/q3_chamados.txt --output consultas/resultado_chamados3.csv --top-k 5 --limit 1000
b) Definição da consulta no arquivo q3_chamados.txt:

FILTER|ano_abertura|==|2026

ORDER|data_hora_abertura|ASC

GROUP|unidade|grupo|dia_abertura

CROSS|unidade|dia_abertura

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=983

OUTPUT_RECORDS=5

LOAD_MS=5.049

SEARCH_MS=0.207

RESULT_INSERT_MS=4.691

WRITE_MS=0.143

d) Tabela construída a partir do arquivo gerado resultado_chamados3.csv:

Solicitação	Atividade	Data/Hora Abertura	Unidade
256932	Remanejar computador	02/01/2026 09:08	Ministério dos Direitos Humanos e da Cidadania
256961	Servidor Windows - Analisar ambiente	02/01/2026 10:17	Ministério dos Direitos Humanos e da Cidadania
256980	Instalar ou desinstalar computador	02/01/2026 11:06	Ministério dos Direitos Humanos e da Cidadania
257001	Instalar ou desinstalar computador	02/01/2026 12:56	Ministério dos Direitos Humanos e da Cidadania
257054	Configurar computador	02/01/2026 15:36	Ministério dos Direitos Humanos e da Cidadania

*Obs: Para o exemplo 2.iii, fizemos testes adicionais para mostrar o formato de agrupamento da saída, comparando a lista ordenada com a lista generalizada e a lista cruzada.

Teste com lista generalizada

a) Comando no terminal: make && ./trabalho --reader chamados --input chamados_dataset.csv --base lista_cabeca --result lista_gen --query consultas/q3_chamados.txt --output consultas/res_q3_chamados_gen.csv --limit 1000

b) Definição da consulta: é a mesma utilizada no exemplo 2.iii

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=983

OUTPUT_RECORDS=983

LOAD_MS=6.206

SEARCH_MS=0.223

RESULT_INSERT_MS=2.630

WRITE_MS=0.729

d) Tabela construída a partir do arquivo gerado res_q3_chamados_gen.csv:

Solicitação	**Data/Hora Abertura**	**Grupo**
256932	02/01/2026 09:08	Executores: 2º Nível - Distrito Federal - Região 4
257054	02/01/2026 15:36	Executores: 2º Nível - Distrito Federal - Região 4
256961	02/01/2026 10:17	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
258264	06/01/2026 15:30	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
259258	08/01/2026 13:46	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
259694	09/01/2026 11:37	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
260728	12/01/2026 17:42	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
261276	13/01/2026 14:02	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows
262682	15/01/2026 13:56	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows

263221	16/01/2026 12:01	Executores: 3º Nível - Infraestrutura de TIC - Sistemas Operacionais - Windows

Com --result lista_gen, os chamados aceitos são organizados na hierarquia definida por GROUP: unidade, depois grupo de atendimento e, dentro de cada grupo, dia de abertura.

Teste com lista cruzada

a) Comando no terminal: make && ./trabalho --reader chamados --input chamados_dataset.csv --base lista_cabeca --result lista_cruz --query consultas/q3_chamados.txt --output consultas/res_q3_chamados_cruz.csv --limit 1000

b) Definição da consulta: é a mesma utilizada no exemplo 2.iii

c) Saída no terminal:

STATUS=OK

INPUT_RECORDS=1000

MATCHED_RECORDS=983

OUTPUT_RECORDS=983

LOAD_MS=9.117

SEARCH_MS=0.373

RESULT_INSERT_MS=2.306

WRITE_MS=0.887

d) Tabela construída a partir do arquivo gerado res_q3_chamados_cruz.csv:

Solicitação	**Data/Hora Abertura**	**Unidade**
268910	29/01/2026 16:24	Ministério dos Direitos Humanos e da Cidadania
268930	29/01/2026 16:50	Ministério dos Direitos Humanos e da Cidadania

257152	05/01/2026 09:07	Ministério das Mulheres
257292	05/01/2026 10:25	Ministério das Mulheres
…	…	…
268904	29/01/2026 16:23	Ministério das Mulheres
268911	29/01/2026 16:26	Ministério das Mulheres
257211	05/01/2026 09:50	Ministério da Igualdade Racial
257266	05/01/2026 10:09	Ministério da Igualdade Racial

Com --result lista_cruz, cada chamado ocupa um único nó, ligado simultaneamente à lista da sua unidade (linha) e à lista do seu dia de abertura (coluna), sem duplicar o registro. A exportação percorre a estrutura pelas linhas: primeiro os 613 chamados do Ministério dos Direitos Humanos e da Cidadania, depois os 272 do Ministério das Mulheres e, por fim, os 98 do Ministério da Igualdade Racial.